Metodologías para el Cálculo de Reservas Técnicas en el Marco Mexicano

Modelos estándar permitidos por la CUSF y requisitos para la adopción de modelos internos sofisticados

Gabriel Fernando Rosas Zepeda

24 de febrero de 2026

Nota: Este documento sintetiza las disposiciones de la Circular Única de Seguros y Fianzas (CUSF) relativas al cálculo de reservas técnicas y al Requerimiento de Capital de Solvencia (RCS), con énfasis en los métodos actuariales explícitamente reconocidos (Parte I) y en los obstáculos que enfrentan los modelos de aprendizaje automático de caja negra para ser aceptados como modelos internos (Parte II).

Resumen

La regulación mexicana de seguros, alineada con el esquema de Solvencia II europeo, exige que las reservas técnicas se calcen como la suma de una Mejor Estimación *(BEL) y un* Margen de Riesgo *(MR). Para facilitar este cálculo, la CUSF ofrece una* Fórmula Estándar *basada en métodos actuariales ampliamente reconocidos (Chain Ladder, Bornhuetter-Ferguson, Mack, Bootstrap). Alternativamente, las instituciones pueden desarrollar* modelos internos*; no obstante, estos deben superar exigentes pruebas estadísticas, de auditabilidad y de gobierno corporativo. Los modelos de Machine Learning de caja negra presentan obstáculos estructurales en prácticamente cada uno de esos requisitos, aunque existen vías de mitigación parcial que se discuten en la segunda parte de este documento.*

Índice

1. Parte I: El Modelo Estándar **3**
1.1. Marco general de las reservas técnicas . . . 3
1.2. Métodos actuariales reconocidos por la CUSF . . . 3
1.2.1. Chain Ladder (Escalera en Cadena) . . . 3
1.2.2. Método de Bornhuetter-Ferguson . . . 3
1.2.3. Método Cape Cod . . . 4
1.2.4. Modelo de Mack . . . 4
1.2.5. Bootstrap (Remuestreo Estadístico) . . . 4
1.2.6. Simulación de Escenarios (Método Estatutario) . . . 4
1.3. El Requerimiento de Capital de Solvencia (RCS) y la Fórmula General 4

2. Parte II: Modelos Internos — ¿Qué debe demostrar una aseguradora? **5**
2.1. Requisitos estadísticos y metodológicos . . . 5
2.1.1. Distribución de probabilidad explícita al 99,5 % . . . 5
2.1.2. Reproducibilidad por profesional independiente . . . 5
2.1.3. Hipótesis, parámetros y fundamentos matemáticos declarados 6
2.1.4. Back-testing y atribución de pérdidas y ganancias (P&L Attribution) . . . 6
2.1.5. Coherencia con métodos actuariales estándar . . . 6
2.1.6. Demostración de equivalencia al 99,5 % . . . 7
2.2. Requisitos de auditoría y gobierno corporativo . . . 7
2.2.1. Comprensión por el Consejo de Administración . . . 7
2.2.2. Explicación por los responsables del modelo . . . 7

2.2.3. Transparencia en la atribución de pérdidas y ganancias por segmento . . . 7
2.2.4. Auditoría interna . . . 8
2.2.5. Revisión independiente y externa anual . . . 8
2.2.6. Opinión favorable del experto independiente . . . 8
2.2.7. Control de versiones y auditoría de cambios . . . 8
2.2.8. Documentación de algoritmos y entrega del código fuente a la CNSF . . . 8
2.3. Prueba de utilización (uso real) . . . 9
2.3.1. Uso efectivo en la toma de decisiones durante al menos un año 9
2.3.2. Pruebas de estrés interpretables por el Consejo . . . 9
2.4. Resumen ejecutivo de obstáculos . . . 10
2.5. Vías de mitigación parcial . . . 11

3. Conclusiones **11**

1. Parte I: El Modelo Estándar

1.1. Marco general de las reservas técnicas

La CUSF establece que toda institución de seguros debe constituir reservas técnicas equivalentes a:

$$\text{Reserva Técnica} = \underbrace{\text{Mejor Estimación (BEL)}}_{\text{valor esperado de flujos futuros}} + \underbrace{\text{Margen de Riesgo (MR)}}_{\text{costo de capital del riesgo no diversificable}} \tag{1}$$

La **Mejor Estimación** se define como la media ponderada por probabilidad de los flujos futuros de obligaciones, descontada con las curvas de tasas libres de riesgo publicadas por la CNSF. El **Margen de Riesgo** se obtiene proyectando los Requerimientos de Capital de Solvencia (RCS) futuros, multiplicándolos por una tasa de costo de capital fijada por la autoridad (históricamente alrededor del 10 %) y trayéndolos a valor presente con la misma curva de descuento libre de riesgo.

Cuando una institución no adopte los ajustes regulatorios en los plazos requeridos, la CNSF le asignará un *Método Estatutario*: los parámetros financieros y técnicos quedan fijados directamente por la autoridad, eliminando la discrecionalidad actuarial de la aseguradora.

1.2. Métodos actuariales reconocidos por la CUSF

La CUSF y sus anexos reconocen y, en muchos casos, *exigen* el uso de los siguientes modelos para el cálculo de reservas, en particular para la Reserva de Siniestros Ocurridos No Reportados (SONR/IBNR):

1.2.1. Chain Ladder (Escalera en Cadena)

Algoritmo **base obligatorio** para proyectar el desarrollo de siniestros a partir de triángulos de desarrollo. Toma los factores de desarrollo histórico (link-ratios) y los aplica sobre los pagos acumulados para estimar el pasivo final. Es el punto de partida para cualquier análisis de IBNR bajo la CUSF.

1.2.2. Método de Bornhuetter-Ferguson

Modelo que combina la experiencia observada con una estimación *a priori* de la pérdida última (derivada de primas esperadas). Es especialmente útil en carteras jóvenes o con escasa historia de siniestros, ya que pondera la información del mercado

con la experiencia propia. La CUSF lo reconoce explícitamente como alternativa a Chain Ladder para afinar proyecciones.

1.2.3. Método Cape Cod

Variante de Bornhuetter-Ferguson en la que la pérdida última esperada se calibra directamente a partir de la prima devengada y la experiencia histórica del ramo, sin necesidad de supuestos externos sobre índices de siniestralidad. También está explícitamente permitido por la normativa.

1.2.4. Modelo de Mack

Extensión estocástica de Chain Ladder que permite calcular la varianza y los **intervalos de confianza** alrededor de la mejor estimación del IBNR, sin asumir una distribución específica de las pérdidas. La CUSF solicita expresamente el cálculo de dichos intervalos de confianza para el Mejor Estimador, haciendo del Modelo de Mack una herramienta de cumplimiento regulatorio.

1.2.5. Bootstrap (Remuestreo Estadístico)

Técnica de simulación que aplica remuestreo sobre los residuos del triángulo de desarrollo para generar distribuciones empíricas de la reserva. La CUSF lo menciona expresamente como método algorítmico válido para la estimación estocástica del IBNR y para la construcción de intervalos de confianza.

1.2.6. Simulación de Escenarios (Método Estatutario)

En el marco del método estatutario, la CUSF prevé la generación de estadísticas por año de origen y de desarrollo para simular reclamaciones futuras, dividendos, ajustes, salvamentos y recuperaciones. Esta simulación alimenta tanto la reserva de riesgos en curso como la reserva para obligaciones pendientes de cumplir por SONR.

1.3. El Requerimiento de Capital de Solvencia (RCS) y la Fórmula General

El Título 8 de la CUSF contiene la *Fórmula General* para calcular el RCS, que es el insumo central del Margen de Riesgo. Sus elementos matemáticos clave son:

- **Valor en Riesgo (VaR):** El RCS cubre pérdidas inesperadas con un nivel de confianza del **99,5 %** a un horizonte de un año. Este es un *requisito matemático duro* que cualquier método —estándar o interno— debe satisfacer.
- **Matrices de correlación:** La CUSF incluye tablas de correlación fijas para agregar los distintos módulos de riesgo (técnico, financiero, de mercado), incorpo-

rando el efecto de diversificación entre riesgos y evitando la suma simple de los peores escenarios.

- **Módulos de riesgo:** Los riesgos se descomponen en submódulos (mortalidad, longevidad, catástrofe, incendio, responsabilidad civil, etc.) con fórmulas y parámetros explícitos para cada uno.

La aseguradora que aplica la Fórmula General con los parámetros publicados por la CNSF obtiene aprobación regulatoria expedita. Si, en cambio, desea sustituir total o parcialmente esa fórmula, debe desarrollar y justificar un *Modelo Interno*.

2. Parte II: Modelos Internos — ¿Qué debe demostrar una aseguradora?

El Capítulo 6.9 de la CUSF regula los modelos internos para el RCS. El umbral de exigencia es considerablemente más alto que el de la Fórmula General. A continuación se resumen, de manera sistemática, los requisitos que debe acreditar una institución que opte por un modelo propio, incluyendo aquellos basados en aprendizaje automático (Machine Learning, AutoML, redes neuronales profundas, *gradient boosting*, etc.).

2.1. Requisitos estadísticos y metodológicos

2.1.1. Distribución de probabilidad explícita al 99,5 %

El modelo debe generar —o ser reconciliable con— una **distribución de probabilidad de pérdidas** para el portafolio completo, calibrada al nivel de confianza del 99,5 % a un horizonte de un año. Si el modelo produce un RCS diferente al de la Fórmula General, la institución debe explicar cómo se reescalan los riesgos y demostrar que el resultado equivale, en términos de solvencia, al estándar del 99,5 %.

Los modelos de caja negra presentan un obstáculo estructural en este punto: sus salidas son típicamente predicciones puntuales o probabilidades de clase, no distribuciones actuarialmente válidas de pérdidas agregadas. Se requiere una capa estadística adicional —que debe ser, a su vez, justificada y auditada— para transformar esas salidas en la distribución exigida.

2.1.2. Reproducibilidad por profesional independiente

La nota metodológica debe alcanzar una calidad y profundidad tales que *cualquier profesional independiente con pericia en el tema pudiera reproducir los resultados del modelo con una precisión razonable*, disponiendo de todos los parámetros e

información. Este requisito excluye, en la práctica, a los modelos con millones de pesos internos cuya lógica de transformación no admite descripción matemática cerrada.

2.1.3. Hipótesis, parámetros y fundamentos matemáticos declarados

La nota técnica debe incluir:

- Las hipótesis y parámetros que sustentan el modelo.
- Las distribuciones, correlaciones y dependencias estadísticas *utilizadas explícitamente*.
- Los supuestos macroeconómicos, de comportamiento y de mitigación, con explicación de cómo reflejan el riesgo actual.
- Un análisis de sensibilidad: qué pasaría con el RCS si se eligieran supuestos razonablemente distintos.

Un modelo de ML aprende relaciones de manera implícita; sus "correlaciones" son pesos internos sin interpretación directa, no parámetros declarables.

2.1.4. Back-testing y atribución de pérdidas y ganancias (P&L Attribution)

La CUSF exige herramientas de validación formal que incluyen:

1. *Back-testing*: verificación de resultados contra experiencia histórica.
2. *Pruebas de robustez*: estabilidad y sensibilidad de los resultados ante cambios en los datos de entrada.
3. *Pruebas de estrés*: simulación de escenarios extremos, capturando no linealidades y colas de distribución.
4. **Atribución de pérdidas y ganancias**: demostrar que los riesgos capturados por el modelo *explican causalmente* las pérdidas y ganancias observadas por segmento de actividad.
5. Análisis comparativo contra modelos de referencia.

El cuarto punto es especialmente exigente para los modelos opacos, porque la CUSF no solo pide que el modelo prediga bien, sino que explique *por qué* se producen las pérdidas y cómo contribuye cada factor de riesgo.

2.1.5. Coherencia con métodos actuariales estándar

El modelo interno debe ser coherente con los métodos empleados para el cálculo de reservas técnicas y con los estándares generalmente aceptados (IAA, IASB, criterios CNSF). Esto implica que los supuestos implícitos del modelo no pueden contradecir

los supuestos actuariales declarados en la valuación de reservas.

2.1.6. Demostración de equivalencia al 99,5 %

Cuando el modelo produzca un RCS distinto al de la Fórmula General, la institución debe presentar una *Demostración de Equivalencia*: una recalibración explícita y justificada que transforme las salidas del modelo en las mediciones de riesgo equivalentes al percentil 99,5. En modelos opacos, esta recalibración resulta circular: se necesita interpretar el modelo para recalibrarlo, pero la interpretabilidad es precisamente lo que falta.

2.2. Requisitos de auditoría y gobierno corporativo

2.2.1. Comprensión por el Consejo de Administración

La CUSF exige que existan sistemas que permitan al Consejo de Administración y a la Dirección General *vigilar que el funcionamiento del modelo refleje apropiadamente el perfil de riesgo*. El personal debe contar con la capacidad técnica para comprender, desarrollar, usar, monitorizar y mantener el modelo. Un modelo cuya lógica interna es opaca imposibilita este nivel de supervisión estructural; las técnicas de explicabilidad post-hoc (SHAP, LIME) son aproximaciones locales que no satisfacen el estándar de comprensión global que la norma demanda.

2.2.2. Explicación por los responsables del modelo

Los responsables del desarrollo y mantenimiento deben ser capaces de *explicar y justificar* cada punto de la nota metodológica: hipótesis, distribuciones, correlaciones, supuestos y técnicas de modelación. Describir el proceso de entrenamiento y las métricas de desempeño no equivale a explicar la lógica causal que conduce al capital requerido.

2.2.3. Transparencia en la atribución de pérdidas y ganancias por segmento

El análisis periódico de causas y orígenes de pérdidas y ganancias debe ser *lo más transparente posible* por segmento de actividad. La atribución de resultados a factores de riesgo individuales en un modelo opaco requiere técnicas post-hoc que son aproximaciones, no explicaciones causales, lo que contradice directamente el espíritu de esta disposición.

2.2.4. Auditoría interna

El Área de Administración de Riesgos debe proveer información al área de auditoría interna para que esta evalúe la efectividad de los controles sobre el modelo. La auditoría no puede verificar la corrección lógica de un modelo opaco: puede revisar los datos de entrada, el proceso de entrenamiento y los resultados, pero no la validez de las relaciones aprendidas internamente, lo que hace que el control sea superficial.

2.2.5. Revisión independiente y externa anual

La política de validación debe contemplar una revisión periódica independiente con periodicidad mínima anual. El experto externo — que debe cumplir estrictos requisitos de independencia y no haber participado en el desarrollo del modelo — difícilmente puede emitir una opinión favorable sobre un modelo cuyos mecanismos internos no puede auditar. Su opinión quedaría limitada a los datos de entrada y los resultados, sin alcanzar la solidez metodológica interna que la norma exige.

2.2.6. Opinión favorable del experto independiente

La institución debe contar con la **opinión favorable** de un experto independiente en matemática actuarial, estadística y desarrollo de modelos, que certifique que el modelo cumple todos los requisitos del Título correspondiente de la CUSF y de los artículos relevantes de la LISF. Esta certificación implica pronunciarse sobre transparencia metodológica, coherencia actuarial y capacidad explicativa: cualidades fundamentalmente incompatibles con la naturaleza opaca de un modelo de caja negra.

2.2.7. Control de versiones y auditoría de cambios

El modelo debe operar sobre una plataforma que permita respaldos, recuperación del sistema, almacenaje de corridas previas, *control de versiones* y auditoría de los cambios. En modelos de ML con reentrenamiento continuo, un mismo código con distintos datos produce modelos diferentes. Demostrar que las diferencias entre versiones son explicables — como lo exige la regulación para cambios mayores — es muy complejo en modelos opacos.

2.2.8. Documentación de algoritmos y entrega del código fuente a la CNSF

La institución debe entregar a la Comisión:

- Los algoritmos con la secuencia de operaciones necesarias para reproducir las salidas del modelo, incluyendo la justificación actuarial de su selección.

- Un sistema de cómputo que permita generar resultados, modificar parámetros y medir sensibilidad.
- El código fuente completo, manuales de usuario, diccionarios de datos, diagramas de relación y plan de contingencia.

Entregar los pesos de una red neuronal o los árboles de un ensemble cumple *formalmente* este requisito, pero no permite que la CNSF evalúe el modelo en términos sustantivos. Además, la dependencia de librerías de terceros (TensorFlow, PyTorch, scikit-learn) y sus licencias añaden complejidad operativa adicional.

2.3. Prueba de utilización (uso real)

2.3.1. Uso efectivo en la toma de decisiones durante al menos un año

La institución debe demostrar que el modelo fue utilizado de manera *consistente y permanente* como parte del sistema de administración integral de riesgos y en el proceso de toma de decisiones, durante al menos el año anterior a la solicitud de aprobación. Este uso debe ser genuino, no meramente formal: los decisores no técnicos (directores, consejeros) deben haber comprendido las salidas del modelo para actuar con base en ellas.

2.3.2. Pruebas de estrés interpretables por el Consejo

El modelo debe ser utilizado en un programa periódico de pruebas de estrés con escenarios extremos cuyos resultados son revisados por el Consejo de Administración. Dichas pruebas deben:

- Revelar información sobre dependencias entre riesgos y no linealidades.
- Arrojar mayor conocimiento sobre las colas de las distribuciones.
- Identificar posibles deficiencias *estructurales* del modelo.

Un modelo opaco puede ejecutarse bajo distintos escenarios, pero no puede explicar causalmente al Consejo por qué responde de determinada manera ante situaciones extremas.

2.4. Resumen ejecutivo de obstáculos

Cuadro 1: Obstáculos estructurales para modelos de ML de caja negra bajo la CUSF

Requisito	Obstáculo principal
Distribución de probabilidad explícita al 99,5 %	Los modelos de ML no generan distribuciones de pérdidas agregadas de forma nativa; se requiere una capa estadística adicional que también debe ser auditada.
Reproducibilidad metodológica	La lógica interna de transformación no puede describirse en términos matemáticos cerrados; solo son reproducibles los resultados, no el razonamiento.
Hipótesis y supuestos explícitos	Las relaciones entre variables son implícitas (pesos, árboles); no existen distribuciones ni correlaciones declaradas formalmente.
Back-testing y atribución de P&L	La atribución causal de pérdidas a factores de riesgo individuales es prácticamente imposible sin interpretabilidad estructural.
Coherencia actuarial	Los estándares IAA/IASB/CNSF no contemplan supuestos implícitos; la coherencia formal con las reservas técnicas no puede demostrarse.
Comprensión por el Consejo	El Consejo no puede vigilar la lógica de un modelo opaco; SHAP/LIME son aproximaciones locales, no comprensión global.
Auditoría interna	Solo pueden auditarse entradas y salidas, no las relaciones internas aprendidas.
Opinión del experto independiente	El experto no puede certificar transparencia metodológica y coherencia actuarial sin poder ver la lógica interna.
Revisión externa anual	La revisión queda limitada a datos y resultados; no alcanza la solidez metodológica que la norma exige.
Control de versiones auditable	El reentrenamiento con nuevos datos produce modelos distintos sin trazabilidad clara de los cambios.
Documentación de algoritmos	La justificación actuarial de la selección del algoritmo (vs. cópulas, cadenas de Markov, etc.) es insuficiente si solo se apoya en métricas de desempeño.
Pruebas de estrés interpretables	Las respuestas ante escenarios extremos no son explicables causalmente al Consejo de Administración.
Demostración de equivalencia al 99,5 %	La recalibración a la distribución del RCS es circular sin interpretabilidad.

2.5. Vías de mitigación parcial

Aunque los obstáculos son sustanciales, existen estrategias que pueden mejorar la viabilidad de un modelo sofisticado dentro del marco de la CUSF:

1. **Modelos de ML inherentemente interpretables.** Utilizar algoritmos transparentes —regresión logística regularizada, árboles de decisión de profundidad limitada, modelos aditivos generalizados (GAMs)— reduce significativamente los obstáculos de transparencia. La desventaja es que se sacrifica parte del poder predictivo de los modelos más complejos.
2. **Capas de explicabilidad global.** Implementar SHAP (SHapley Additive exPlanations) a nivel *global* —no solo local— para aproximar la atribución de riesgos al portafolio completo. Esto no resuelve el problema de fondo, pero mejora la auditabilidad y la comunicación al Consejo.
3. **Arquitectura híbrida.** Usar el modelo de ML como *componente de estimación* dentro de un marco actuarial explícito y auditable: el modelo de ML es un insumo (por ejemplo, para estimar frecuencias o severidades), mientras que el motor de decisión del RCS sigue siendo el marco actuarial declarado y verificable.
4. **Documentación exhaustiva del proceso de entrenamiento.** Incluir evidencia detallada de diseño, selección y justificación de variables, validación cruzada, pruebas de estabilidad, benchmarking contra modelos de referencia actuariales y análisis de sensibilidad, para compensar parcialmente la opacidad interna del modelo.
5. **Validación externa especializada.** Contratar expertos independientes con experiencia específica en la intersección de ML y regulación actuarial, capaces de emitir opiniones técnicas fundamentadas sobre el desempeño y la robustez del modelo. La opinión sobre la transparencia metodológica seguirá siendo el *nudo crítico* y probablemente el punto de mayor negociación con la CNSF.

3. Conclusiones

La CUSF ofrece a las aseguradoras mexicanas un menú de herramientas actuariales estándar — Chain Ladder, Bornhuetter-Ferguson, Cape Cod, Mack, Bootstrap — que constituyen el camino de menor resistencia regulatoria para el cálculo de reservas técnicas y del RCS. Quienes elijan este camino obtienen aprobación expedita, a cambio de adoptar parámetros y supuestos que pueden no reflejar con precisión las particularidades de su cartera.

Los modelos internos, incluyendo los basados en Machine Learning, abren la puerta a una modelación más precisa y adaptada al perfil de riesgo institucional. Sin embargo,

la CUSF impone un estándar de exigencia que va mucho más allá del desempeño predictivo: el modelo debe ser *transparente, reproducible, coherente con la práctica actuarial, auditable* por terceros independientes y *comprensible* por el Consejo de Administración.

Los modelos de caja negra, por su propia naturaleza, presentan obstáculos estructurales en la mayoría de esas dimensiones. La ruta más viable para incorporarlos en el marco regulatorio mexicano pasa por arquitecturas híbridas en las que el componente de ML actúa como auxiliar de estimación dentro de un armazón actuarial explícito, o por el uso de algoritmos inherentemente interpretables que renuncian a parte del poder predictivo a cambio de transparencia regulatoria.

Análisis elaborado con base en el texto oficial del Capítulo 6.9 y los Títulos 5 y 8 de la Circular Única de Seguros y Fianzas (CUSF), versión compulsada al 07-10-2024, publicada por la Comisión Nacional de Seguros y Fianzas (CNSF) de México.